

Relazione - Versione 2: Data Inspector

Introduzione

La Versione 2 estende la prima versione funzionante del progetto Building Agentic AutoML introducendo un passaggio dedicato all'ispezione del dataset.

L'agente continua a ricevere dataset e target, rilevare il task, preparare i dati, addestrare un baseline LightGBM, valutarlo e restituire uno stato strutturato. La nuova capacità consiste nel profilare il dataset prima del training, così che lo stato contenga anche informazioni su dimensioni, comportamento del target, tipi delle feature, valori mancanti e cardinalità.

Questa versione si concentra sul seguente flusso:

```
Dataset + target
↓
Rilevare task e feature
↓
Ispezionare il dataset
↓
Preparare dati e baseline
↓
Valutare
↓
Restituire stato + inspection
```

L'architettura rimane volutamente semplice: un solo modello, un train-validation split e nessuna ottimizzazione. La Versione 2 aggiunge osservabilità sul dataset senza cambiare la strategia di training di base.

Obiettivo della Versione 2

L'obiettivo della Versione 2 è rendere l'agente più informato prima dell'addestramento, mantenendo l'architettura minimale introdotta nella Versione 1.

L'agente deve ora essere in grado di:

- caricare dataset e target;
- distinguere classificazione e regressione;
- identificare feature numeriche e categoriche;
- ispezionare dimensioni del dataset, distribuzione o statistiche del target, tipi delle feature, valori mancanti e cardinalità;
- selezionare modello e metrica;
- addestrare, valutare e restituire l'inspection insieme allo stato.

L'esempio principale di classificazione utilizza ora Adult Income, un dataset tabellare più realistico che contiene anche valori mancanti in alcune colonne categoriche.

Architettura

Il flusso della Versione 2 è:

```
Dataset + Target → Task/Features → Data Inspection → Preparation
→ Model/Metric → Evaluation → State
```

La funzione agent continua a coordinare direttamente l'intero flusso. Il nuovo componente `inspect_dataset` viene chiamato prima della preparazione dei dati e il suo risultato viene salvato nello stato finale.

Rilevamento del task

Il rilevamento del task rimane invariato rispetto alla Versione 1. L'agente analizza la colonna target e usa il numero di valori unici come regola semplice: al massimo 20 valori unici significa classificazione; altrimenti il task viene considerato regressione.

```
def detect_task(df, target):
    n_unique = df[target].nunique()
    if n_unique <= 20:
        return "classification"
    return "regression"
```

Per il target income di Adult Income il risultato è:

```
"classification"
```

Rilevamento delle feature

L'agente separa le feature numeriche da quelle categoriche utilizzando direttamente i dtype del dataframe.

Per Adult Income rileva 6 feature numeriche e 8 categoriche:

```
numerical = ['age', 'fnlwt', 'education_num',
             'capital_gain', 'capital_loss', 'hours_per_week']

categorical = ['workclass', 'education', 'marital_status', 'occupation',
              'relationship', 'race', 'sex', 'native_country']
```

Data Inspection

Questo è il nuovo componente introdotto nella Versione 2. Prima del training, inspect_dataset crea un profilo compatto del dataset.

shape	→ righe e colonne
target	→ nome, dtype, valori unici, distribuzione/statistiche
dtypes	→ tipi delle feature
missing_values	→ numero di valori mancanti per colonna
cardinality	→ numero di valori unici non nulli per feature

Per Adult Income, l'inspection rileva 48.842 righe e 15 colonne. Il target contiene due classi: ≤50K con 37.155 righe e >50K con 11.687 righe.

I principali valori mancanti sono workclass = 2.799, occupation = 2.809 e native_country = 857.

L'inspector espone inoltre la cardinalità delle feature, ad esempio education = 16, occupation = 14 e native_country = 41.

L'inspection è solamente descrittiva: segnala la struttura del dataset ma non effettua ancora imputazione dei missing value, rimozione degli outlier o trasformazioni delle feature.

Preparazione dei dati

Come nella Versione 1, le colonne categoriche vengono convertite nel dtype pandas category e le feature X vengono separate dal target y. LightGBM gestisce quindi direttamente le variabili categoriche.

Modello baseline e selezione della metrica

La scelta di modello e metrica rimane invariata. La classificazione usa LGBMClassifier con ROC AUC, mentre la regressione usa LGBMRegressor con RMSE. Entrambi i modelli utilizzano random_state=42 e la configurazione di default di LightGBM.

```
classification → LGBMClassifier + ROC AUC
regression      → LGBMRegressor + RMSE
```

Addestramento e valutazione

L'agente usa un singolo train-validation split con test_size=0.2 e random_state=42. Per la classificazione utilizza anche stratify=y, così da preservare le proporzioni delle classi.

Su Adult Income il notebook ottiene:

```
model = LGBMClassifier
metric = roc_auc
score = 0.9311658417981501
```

Il risultato conferma che il pipeline baseline originale continua a funzionare sul dataset più realistico dopo l'aggiunta del passaggio di inspection.

Agent

Nella Versione 2, l'Agent esegue le seguenti operazioni:

1. carica dataset e target
2. rileva classificazione o regressione
3. identifica feature numeriche e categoriche
4. ispeziona il dataset
5. prepara i dati
6. seleziona modello e metrica
7. addestra e valuta il baseline
8. restituisce lo stato finale includendo l'inspection

Uno stato semplificato contiene ora:

```
{
  "task": "classification",
  "inspection": {
    "shape": {"rows": 48842, "columns": 15},
    "target": {"name": "income", "unique_values": 2},
    "missing_values": {...},
    "cardinality": {...}
  },
  "model": "LGBMClassifier",
  "metric": "roc_auc",
  "score": 0.9311658417981501
}
```

Lo stato è quindi più informativo rispetto alla Versione 1: registra non solo le decisioni e il risultato della valutazione, ma anche il profilo del dataset utilizzato prima del training.

Test di regressione

Lo stesso agente viene testato su simple_regression.csv con la colonna target "target". L'agente rileva automaticamente la regressione e produce anche un'inspection specifica, in cui il target continuo viene descritto con statistiche riassuntive invece di una distribuzione di classi.

```
task = regression
model = LGBMRegressor
metric = rmse
score = 1.8760451113860066
```

Il test di regressione conferma che la logica di inspection si adatta sia a target discreti sia a target continui senza modificare il flusso dell'agente.

Cosa insegna la Versione 2

La Versione 2 introduce un'idea fondamentale dell'AutoML: un agente dovrebbe comprendere la struttura del dataset prima di addestrare un modello.

L'idea principale diventa:

osservare → ispezionare → decidere → preparare → addestrare → valutare → restituire

Il nuovo passaggio di inspection rende lo stato dell'agente più trasparente. Espone dimensioni del dataset, comportamento del target, tipi delle feature, valori mancanti e cardinalità, segnali utili per future decisioni automatiche.

Questo stabilisce anche un pattern evolutivo chiaro per il progetto: ogni versione introduce una capacità aggiuntiva, preservando quando possibile il baseline già funzionante.

Limitazioni

La Versione 2 mantiene alcune limitazioni intenzionali:

- il rilevamento del task usa ancora soltanto il numero di valori unici del target;
- il Data Inspector segnala i missing value ma non li imputa;
- l'inspector non rileva ancora outlier, leakage, righe duplicate, skewness o tipi semantici;
- viene utilizzata una sola famiglia di modelli, LightGBM;
- non esiste confronto tra più algoritmi né ricerca degli iperparametri;
- la valutazione usa ancora un solo train-validation split;
- non esiste cross-validation;
- non esiste ancora un planner o un sistema multi-agent.

Queste limitazioni sono deliberate. Lo scopo della Versione 2 è l'ispezione, non la correzione automatica dei problemi o l'ottimizzazione.

Conclusione

La Versione 2 estende il baseline di Building Agentic AutoML con un Data Inspector, mantenendo la semplicità della Versione 1.

L'agente può ora ispezionare un dataset realistico, rendere esplicita la sua struttura e alcuni segnali di qualità, addestrare lo stesso baseline LightGBM e restituire l'inspection insieme a task, feature, modello, metrica e score.

La lezione principale è che l'AutoML agentic diventa più utile quando le decisioni sono fondate su una rappresentazione esplicita dei dati. La Versione 2 fornisce questo primo livello di consapevolezza del dataset e prepara il progetto a versioni successive capaci di agire sulle informazioni scoperte durante l'inspection.