

Relazione - Versione 5: Smart Validation

La Versione 5 estende **Building Agentic AutoML** introducendo una strategia di validazione più robusta.

L'agente mantiene task detection, feature detection, Data Inspection, le due strategie di preprocessing e i tre modelli candidati della Versione 4. La nuova capacità consiste nel valutare ogni combinazione preprocessing-modello con **cross-validation** e nel selezionare il miglior esperimento usando lo score medio sui fold.

Questa versione mantiene volutamente invariati modelli, metriche e configurazioni degli iperparametri, così che il nuovo concetto sia uno solo: **Smart Validation**.

Obiettivo della Versione 5

- mantenere invariati i componenti introdotti nelle Versioni 1-4;
- sostituire il singolo train-validation split con una validazione task-aware;
- usare **StratifiedKFold** per classificazione e **KFold** per regressione;
- valutare ogni combinazione preprocessing-modello su 5 fold;
- salvare fold score, media e deviazione standard di ogni esperimento;
- restituire best_preprocessing, best_model, best_score e best_std.

Architettura

```
Dataset + Target -> Task/Features -> Data Inspection -> Preprocessing  
Strategies -> Model Candidates -> Smart Validation -> Evaluation -> Best  
Experiment -> State
```

Rilevamento del task

Il rilevamento del task rimane invariato rispetto alla Versione 4: al massimo 20 valori unici del target significa classificazione, altrimenti regressione.

```
def detect_task(df, target): n_unique = df[target].nunique() if n_unique <= 20: return "classification" return "regression"
```

Rilevamento delle feature

Anche il rilevamento delle feature rimane invariato. Su Adult Income vengono rilevate 6 feature numeriche e 8 categoriche.

Data Inspection

Il Data Inspector della Versione 2 viene mantenuto invariato. Su Adult Income rileva 48.842 righe, 15 colonne, due classi target, dtype, missing value e cardinalità. I principali missing restano workclass = 2.799, occupation = 2.809 e native_country = 857.

Preprocessing

La Versione 5 conserva le strategie **native** e **impute**. I parametri di imputazione vengono appresi esclusivamente dal training fold, evitando leakage tra training e validation fold.

Model Selection

LightGBM, XGBoost e CatBoost restano i tre candidati introdotti nella Versione 4. Non viene eseguita ricerca degli iperparametri, così da isolare l'effetto della nuova strategia di validazione.

Selezione della metrica

La logica della metrica rimane invariata: ROC AUC per classificazione e RMSE per regressione.

Smart Validation

Questa è la nuova capacità della Versione 5. Per la classificazione l'agente seleziona **StratifiedKFold**; per la regressione seleziona **KFold**. Entrambi usano 5 fold, shuffle=True e random_state=42. Per ogni esperimento vengono conservati fold_scores, mean_score e std_score; la selezione finale usa mean_score.

Addestramento e valutazione

Ogni combinazione preprocessing-modello viene addestrata e valutata su tutti i 5 fold. Il preprocessing viene rifatto all'interno di ciascun fold e ogni fold usa una nuova istanza del modello. In questo modo la stima è più stabile rispetto al singolo split della Versione 4.

Risultati - Adult Income

Preprocessing	Model	Mean ROC AUC	Std
native	LightGBM	0.929556	0.002508
native	XGBoost	0.926851	0.002227
native	CatBoost	0.930631	0.002246
impute	LightGBM	0.929217	0.002713
impute	XGBoost	0.926435	0.002643
impute	CatBoost	0.930119	0.002428

Miglior esperimento: **CatBoost + native**, ROC AUC medio = **0.9306306263**, std = **0.0022463105**.

Agent

- carica dataset e target;
- rileva task e tipi di feature;
- ispeziona il dataset;
- prepara X e y;
- seleziona metrica e strategia di validazione;
- costruisce i modelli candidati;
- valuta ogni preprocessing x modello su 5 fold;
- salva fold score, media e deviazione standard;
- seleziona il miglior esperimento in base alla media;
- restituisce lo stato finale.

```
{ "task": "classification", "metric": "roc_auc", "validation":  
  "StratifiedKFold", "n_splits": 5, "best_preprocessing": "native",  
  "best_model": "CatBoost", "best_score": 0.930630626301291, "best_std":  
  0.002246310473216, "experiments": [...] }
```

Test di regressione

Lo stesso agente viene eseguito su `simple_regression.csv`. Rileva automaticamente la regressione, seleziona KFold, usa RMSE e valuta gli stessi tre modelli con entrambe le strategie di preprocessing.

Preprocessing	Model	Mean RMSE	Std
native	LightGBM	1.843523	0.107316
native	XGBoost	2.015096	0.065982
native	CatBoost	1.663274	0.103853
impute	LightGBM	1.856696	0.120398
impute	XGBoost	2.055328	0.130456
impute	CatBoost	1.628342	0.101940

Miglior esperimento: **CatBoost + impute**, RMSE medio = **1.6283421164**, std = **0.1019398476**.

Cosa insegna la Versione 5

La Versione 5 introduce l'idea che una scelta AutoML affidabile non debba dipendere da un singolo split. L'agente deve stimare la performance su più fold e conservare anche la variabilità dei risultati.

La progressione rimane esplicita: V1 costruisce il baseline, V2 osserva i dati, V3 sperimenta sul preprocessing, V4 confronta i modelli e V5 rende la validazione più robusta. Il principio **One Version, One Concept** resta rispettato.

Limitazioni

- task detection ancora basata solo sul numero di valori unici del target;
- solo due strategie di preprocessing;
- solo tre boosting model candidati;
- cross-validation fissa a 5 fold, senza logiche group-aware o time-series-aware;
- nessuna ottimizzazione degli iperparametri;
- nessun feature engineering, planner o architettura multi-agent;
- lo stato conserva risultati e decisione, ma non ancora una pipeline fitted persistente.

Conclusione

La Versione 5 sostituisce il singolo train-validation split con una cross-validation task-aware senza alterare preprocessing, modelli, metriche o iperparametri. Su Adult Income il miglior esperimento diventa CatBoost + native; sul test di regressione resta CatBoost + impute. La versione rende la selezione più stabile e prepara il progetto a successive evoluzioni dell'ottimizzazione AutoML.