

Relazione - Versione 7: Hyperparameter Optimization

La Versione 7 estende **Building Agentic AutoML** introducendo il confronto automatico di configurazioni di iperparametri.

L'agente mantiene task detection, feature detection, Data Inspection, le due strategie di preprocessing, le due strategie di feature engineering, i tre modelli candidati e la Smart Validation della Versione 6. La nuova capacita consiste nel valutare, per ogni modello, una configurazione baseline e una configurazione alternativa.

Con 2 preprocessing, 2 strategie di feature engineering, 3 modelli, 2 configurazioni e 5 fold, l'agente confronta **24 esperimenti** e realizza **120 fit per dataset**. Metriche e validazione restano invariate, così che il nuovo concetto sia uno solo: **Hyperparameter Optimization**.

Obiettivo della Versione 7

- mantenere invariati i componenti introdotti nelle Versioni 1-6;
- aggiungere piccoli search space specifici per LightGBM, XGBoost e CatBoost;
- mantenere la configurazione della Versione 6 come baseline e confrontarla con una configurazione alternativa;
- valutare ogni combinazione preprocessing x feature engineering x modello x iperparametri su 5 fold;
- salvare iperparametri, fold score, media e deviazione standard di ogni esperimento;
- restituire best_preprocessing, best_feature_engineering, best_model, best_params, best_score e best_std.

Architettura

```
Dataset + Target -> Task/Features -> Data Inspection -> Preprocessing  
Strategies -> Feature Engineering -> Model Candidates -> Hyperparameter  
Optimization -> Smart Validation -> Evaluation -> Best Experiment -> State
```

Rilevamento del task

Il rilevamento del task rimane invariato: al massimo 20 valori unici del target significa classificazione, altrimenti regressione.

```
def detect_task(df, target): n_unique = df[target].nunique() if n_unique <= 20:  
    return "classification" return "regression"
```

Rilevamento delle feature

Anche il rilevamento delle feature rimane invariato. Su Adult Income vengono rilevate 6 feature numeriche e 8 categoriche.

Data Inspection

Il Data Inspector della Versione 2 viene mantenuto invariato. Su Adult Income rileva 48.842 righe, 15 colonne, due classi target, dtype, missing value e cardinalità. I principali missing restano workclass = 2.799, occupation = 2.809 e native_country = 857.

Preprocessing

La Versione 7 conserva le strategie **native** e **impute**. I parametri di imputazione vengono appresi esclusivamente dal training fold.

Feature Engineering

Il layer della Versione 6 resta invariato: **none** mantiene lo spazio originale; **interactions** aggiunge prodotti pairwise tra feature numeriche. Le feature originali sono sempre preservate.

Model Selection

LightGBM, XGBoost e CatBoost restano i tre candidati introdotti nella Versione 4.

Hyperparameter Optimization

Questa è la nuova capacità della Versione 7. Ogni modello confronta la configurazione baseline della Versione 6 con una configurazione alternativa predefinita:

- **LightGBM**: n_estimators=200, learning_rate=0.05, num_leaves=31;
- **XGBoost**: n_estimators=200, learning_rate=0.05, max_depth=4;
- **CatBoost**: iterations=500, learning_rate=0.05, depth=6.

Selezione della metrica

La logica della metrica rimane invariata: ROC AUC per classificazione e RMSE per regressione.

Smart Validation

La validazione della Versione 5 resta invariata: **StratifiedKFold** per classificazione e **KFold** per regressione, entrambi con 5 fold, shuffle=True e random_state=42.

Addestramento e valutazione

Ogni combinazione preprocessing-feature engineering-modello-iperparametri viene valutata sui 5 fold. Con 2 preprocessing, 2 strategie di feature engineering, 3 modelli e 2 configurazioni, l'agente confronta 24 esperimenti e realizza 120 fit. In ogni fold: preprocessing -> feature engineering -> nuova istanza del modello con i parametri da valutare.

Risultati - Adult Income

Cfg: B = baseline Versione 6; T = configurazione alternativa della Versione 7.

Preproc.	Feature Eng.	Model	Cfg	Mean ROC AUC	Std
native	none	LightGBM	B	0.929556	0.002508
native	none	LightGBM	T	0.929846	0.002751
native	none	XGBoost	B	0.926851	0.002227
native	none	XGBoost	T	0.926509	0.002680
native	none	CatBoost	B	0.930631	0.002246
native	none	CatBoost	T	0.929910	0.002476
native	interactions	LightGBM	B	0.928578	0.002922
native	interactions	LightGBM	T	0.928841	0.002925
native	interactions	XGBoost	B	0.925359	0.002862
native	interactions	XGBoost	T	0.926751	0.003077
native	interactions	CatBoost	B	0.929786	0.002187
native	interactions	CatBoost	T	0.929101	0.002568
impute	none	LightGBM	B	0.929217	0.002713
impute	none	LightGBM	T	0.929522	0.002606
impute	none	XGBoost	B	0.926435	0.002643
impute	none	XGBoost	T	0.926525	0.002548
impute	none	CatBoost	B	0.930119	0.002428
impute	none	CatBoost	T	0.929409	0.002501
impute	interactions	LightGBM	B	0.928319	0.002660
impute	interactions	LightGBM	T	0.928699	0.002746
impute	interactions	XGBoost	B	0.925207	0.002604
impute	interactions	XGBoost	T	0.926060	0.002873
impute	interactions	CatBoost	B	0.929030	0.002533
impute	interactions	CatBoost	T	0.928672	0.002474

Miglior esperimento: **CatBoost + native + none + baseline**, ROC AUC medio = **0.9306306263**, std = **0.0022463105**.

Agent

- carica dataset e target; rileva task e tipi di feature; ispeziona il dataset;
- seleziona metrica e strategia di validazione;
- costruisce i modelli candidati e i search space;
- valuta ogni preprocessing x feature engineering x modello x iperparametri su 5 fold;
- salva configurazione, fold score, media e deviazione standard;
- seleziona il miglior esperimento in base alla media e restituisce lo stato finale.

```
{ "task": "classification", "metric": "roc_auc", "validation": "StratifiedKFold",  
  "n_splits": 5, "best_preprocessing": "native", "best_feature_engineering": "none",  
  "best_model": "CatBoost", "best_params": {}, "best_score": 0.930630626301291,  
  "best_std": 0.002246310473216, "experiments": [...] }
```

Test di regressione

Lo stesso agente viene eseguito su `simple_regression.csv`. Rileva automaticamente la regressione, seleziona KFold, usa RMSE e valuta le 24 combinazioni preprocessing-feature engineering-modello-iperparametri.

Cfg: B = baseline Versione 6; T = configurazione alternativa della Versione 7.

Preproc.	Feature Eng.	Model	Cfg	Mean RMSE	Std
native	none	LightGBM	B	1.843523	0.107316
native	none	LightGBM	T	1.822595	0.094805
native	none	XGBoost	B	2.015096	0.065982
native	none	XGBoost	T	1.777285	0.088175
native	none	CatBoost	B	1.663274	0.103853
native	none	CatBoost	T	1.668889	0.090802
native	interactions	LightGBM	B	1.857629	0.117062
native	interactions	LightGBM	T	1.835923	0.128336
native	interactions	XGBoost	B	2.114515	0.127715
native	interactions	XGBoost	T	1.820967	0.098845
native	interactions	CatBoost	B	1.728558	0.113004
native	interactions	CatBoost	T	1.736163	0.128649
impute	none	LightGBM	B	1.856696	0.120398
impute	none	LightGBM	T	1.836213	0.114397
impute	none	XGBoost	B	2.055328	0.130456
impute	none	XGBoost	T	1.797339	0.088521
impute	none	CatBoost	B	1.628342	0.101940
impute	none	CatBoost	T	1.607846	0.100120
impute	interactions	LightGBM	B	1.893113	0.114140
impute	interactions	LightGBM	T	1.852828	0.098626
impute	interactions	XGBoost	B	2.051424	0.112415
impute	interactions	XGBoost	T	1.816835	0.105434
impute	interactions	CatBoost	B	1.681678	0.112769
impute	interactions	CatBoost	T	1.670252	0.104809

Miglior esperimento: **CatBoost + impute + none + tuned**, RMSE medio = **1.6078463494**, std = **0.1001204396**.

Cosa insegna la Versione 7

La Versione 7 introduce l'idea che anche gli iperparametri debbano essere trattati come una scelta AutoML da confrontare empiricamente. Sul benchmark di classificazione la configurazione baseline di CatBoost resta migliore; sul benchmark di regressione la configurazione alternativa di CatBoost migliora il miglior RMSE da 1.628342 a 1.607846.

La progressione rimane esplicita: V1 costruisce il baseline, V2 osserva i dati, V3 sperimenta sul preprocessing, V4 confronta i modelli, V5 rende la validazione più robusta, V6 confronta spazi di feature e V7 confronta configurazioni di iperparametri. Il principio **One Version, One Concept** resta rispettato.

Limitazioni

- search space intenzionalmente ridotto: solo due configurazioni per modello;
- nessuna Bayesian optimization, random search o early stopping dedicato;
- cross-validation fissa a 5 fold, senza logiche group-aware o time-series-aware;
- feature engineering ancora limitato a prodotti pairwise numerici;
- solo tre boosting model candidati;
- nessun planner o architettura multi-agent;
- lo stato non conserva ancora una pipeline fitted persistente.

Conclusione

La Versione 7 aggiunge un primo livello di Hyperparameter Optimization senza alterare preprocessing, feature engineering, modelli, metriche o validazione. L'agente ora confronta configurazioni, conserva i risultati e seleziona i parametri migliori insieme al resto della pipeline, preparando la Versione 8.