

Relazione - Versione 8: Autonomous Experiment Planning

La Versione 8 estende **Building Agentic AutoML** introducendo un **Senior Agent** responsabile della pianificazione autonoma degli esperimenti.

Lo spazio di ricerca della Versione 7 resta disponibile, ma non viene più esplorato in modo esaustivo. Il Senior Agent usa Data Inspection e risultati precedenti per scegliere quale esperimento eseguire successivamente, entro un budget fisso e con una decision history trasparente.

Con 2 preprocessing, 2 strategie di feature engineering, 3 modelli e 2 configurazioni restano **24 esperimenti candidati**. Con il budget predefinito di 10, l'agente esegue **10 esperimenti** (riduzione del 58,33%) e al massimo 50 fit con 5 fold, invece dei 120 fit della ricerca esaustiva della Versione 7.

Obiettivo della Versione 8

- mantenere disponibili i componenti introdotti nelle Versioni 1-7;
- distinguere classificazione binaria, classificazione multiclass e regressione;
- costruire lo stesso pool di 24 candidati ma selezionare solo gli esperimenti ritenuti utili entro il budget;
- stabilire una baseline per LightGBM, XGBoost e CatBoost e adattare le scelte successive ai risultati osservati;
- registrare motivazione, stato, score, tempo di esecuzione e traiettoria del miglior risultato;
- restituire la migliore configurazione osservata insieme alla completa decision history.

Architettura

```
Dataset + Target -> Task/Features -> Data Inspection -> Candidate Experiment Space  
-> Senior Agent Planner -> Selected Experiment -> Cross-Validation Evaluation  
-> Decision History / State -> Best Observed Configuration
```

Rilevamento del task

La Versione 8 estende il rilevamento del task: distingue classificazione binaria, classificazione multiclass e regressione. I target non numerici sono classificazione; per i target numerici vengono considerati sia il numero di valori unici sia il loro rapporto rispetto alle osservazioni.

Rilevamento delle feature

Le feature continuano a essere separate in numeriche e categoriche tramite i dtype. Su Adult Income vengono rilevate 6 feature numeriche e 8 categoriche.

Data Inspection

L'ispezione ora salva dimensioni, tipo e distribuzione del target, dtype, missing count e percentuali, cardinalità e righe duplicate. Su Adult Income rileva 48.842 righe, 15 colonne, 52 duplicati e missing in `workclass` = 2.799, `occupation` = 2.809 e `native_country` = 857.

Preprocessing

Restano le strategie **native** e **impute**. I parametri di imputazione sono appresi esclusivamente dal training fold; la gestione è resa più robusta anche per colonne completamente mancanti.

Feature Engineering

Restano **none** e **interactions**. Le interazioni sono prodotti pairwise tra feature numeriche e vengono create dentro ciascun fold dopo il preprocessing.

Model Selection

LightGBM, XGBoost e CatBoost restano i tre candidati. I classifier vengono inizializzati in modo coerente con task binario o multiclass; i regressor restano invariati.

Experiment Space

Le combinazioni definiscono un pool di **24 candidati** (2 preprocessing x 2 feature engineering x 3 modelli x 2 configurazioni), separando lo spazio disponibile dalla policy che decide cosa eseguire.

Selezione della metrica

ROC AUC per classificazione binaria, **ROC AUC OvR Macro** per multiclass e **RMSE** per regressione.

Smart Validation

StratifiedKFold per classificazione e **KFold** per regressione. Il default è 5 fold; nei problemi di classificazione il numero di fold viene ridotto automaticamente quando la classe più piccola contiene meno di 5 osservazioni.

Addestramento e valutazione

Ogni candidato selezionato viene valutato nei fold con preprocessing e feature engineering interni alla validazione. La Versione 8 aggiunge supporto multiclass, tempo di esecuzione, status esplicito e gestione dei fallimenti senza interrompere l'intero processo.

Senior Agent Planning

Questa è la nuova capacità della Versione 8. La policy è deterministica e sequenziale: usa risultati completati e missing value per decidere il prossimo esperimento.

- Stage 1: stabilire una baseline native + none + default per ogni famiglia di modelli;
- Stage 2: provare la configurazione alternativa del modello attualmente migliore;
- Stage 3: se esistono missing value, confrontare il preprocessing alternativo mantenendo il resto della migliore configurazione;
- Stage 4: testare le interazioni numeriche attorno alla configurazione migliore;
- Stage 5: usare il budget residuo per esplorare candidati non ancora testati.

Risultati - Adult Income

Cfg: **B** = baseline; **T** = configurazione alternativa. Il planner esegue 10 esperimenti su 24.

Step	Preproc.	Feature Eng.	Model	Cfg	Mean AUC	Sec
1	native	none	LightGBM	B	0.929556	4.08
2	native	none	XGBoost	B	0.926851	4.44
3	native	none	CatBoost	B	0.930631	250.66
4	native	none	CatBoost	T	0.929910	121.42
5	impute	none	CatBoost	B	0.930119	198.22
6	native	interactions	CatBoost	B	0.929786	215.24
7	native	none	LightGBM	T	0.929846	4.57
8	native	none	XGBoost	T	0.926509	4.43
9	native	interactions	LightGBM	B	0.928578	3.49
10	native	interactions	LightGBM	T	0.928841	5.91

Migliore configurazione osservata: **CatBoost + native + none + baseline**, ROC AUC medio = **0.9306306263**, std = **0.0022463105**.

Budget: **10/24 esperimenti** - riduzione = **58,33%** - durata totale osservata = **812,45 s**.

Decision history

Le prime tre mosse stabiliscono le baseline. CatBoost diventa subito il migliore; tuning, imputazione e interazioni non superano la baseline su Adult. Gli ultimi step usano il budget residuo per esplorazione. La migliore soluzione della Versione 7 viene quindi recuperata senza eseguire tutti i 24 candidati.

Test di generalizzazione

Lo stesso agent() viene eseguito senza modificare la planning policy su Wine, California Housing mixed-type e California Housing numeric. Tutti i benchmark usano 10 esperimenti su 24 e 5 fold.

Dataset	Task	Metric	Best	Preproc.	Feature Eng.	Score	Std	Sec
Adult Income	binary	ROC AUC	CatBoost	native	none	0.930631	0.002246	812.45
Wine	multiclass	AUC OvR Macro	CatBoost	native	none	0.998847	0.001814	90.39
California Housing	regression	RMSE	CatBoost	impute	interactions	45482.05	1289.98	229.36
California Numeric	regression	RMSE	CatBoost	native	interactions	45703.19	1375.85	86.30

Wine - classificazione multiclass

Il task viene rilevato come multiclass, la metrica diventa ROC AUC OvR Macro e la validazione resta StratifiedKFold. CatBoost + native + none raggiunge 0.998847 con std 0.001814. Senza missing value, la policy non prioritizza l'imputazione nei 10 step osservati.

California Housing - regressione mixed-type

Il task passa automaticamente a regressione con KFold e RMSE. I missing in total_bedrooms attivano il confronto del preprocessing alternativo: la migliore configurazione osservata diventa CatBoost + impute + interactions, RMSE 45.482,05.

California Housing - regressione numerica

Nel dataset numerico completo non ci sono missing value. La policy usa il budget su modelli, tuning e feature engineering; il migliore risultato è CatBoost + native + interactions, RMSE 45.703,19.

Comportamento del planner

I risultati mostrano che la stessa policy cambia traiettoria in base ai dati: su California mixed esplora l'imputazione perché i missing sono presenti, mentre sul dataset numerico non la prioritizza. La decision history rende esplicita questa differenza.

Cosa insegna la Versione 8

La Versione 8 sposta il progetto da una ricerca esaustiva a una ricerca adattiva: non cambia il pool di strumenti, ma introduce un componente che decide quali esperimenti meritano il budget disponibile.

Su Adult Income il Senior Agent recupera la **stessa migliore configurazione della Versione 7** (CatBoost + native + none + baseline) eseguendo 10 esperimenti invece di 24. Il risultato evidenzia il valore del planning senza attribuire alla policy garanzie di ottimalità globale.

La progressione resta esplicita: V1 costruisce il baseline, V2 osserva i dati, V3 sperimenta sul preprocessing, V4 confronta i modelli, V5 rende la validazione più robusta, V6 confronta gli spazi di feature, V7 confronta configurazioni di iperparametri e V8 decide autonomamente quali esperimenti eseguire. Il principio One Version, One Concept resta rispettato.

Limitazioni

- planning policy intenzionalmente semplice, deterministica e rule-based;
- budget espresso come numero di esperimenti; il tempo viene registrato ma non influenza ancora le scelte;
- nessuna Bayesian optimization, reinforcement learning, LLM planning o early stopping dedicato;
- la migliore configurazione è selezionata e riportata sulla stessa cross-validation usata per il model selection, senza holdout finale indipendente;
- task detection ancora euristico per target numerici discreti;
- feature engineering limitato a interazioni pairwise numeriche e solo tre boosting model candidati;
- lo stato non conserva ancora una pipeline fitted persistente.

Conclusione

La Versione 8 introduce Autonomous Experiment Planning senza sostituire i componenti costruiti nelle versioni precedenti. Il Senior Agent costruisce lo spazio di candidati, pianifica ed esegue una sequenza limitata di esperimenti, registra la motivazione di ogni scelta e restituisce la migliore configurazione osservata con la completa decision history. Il progetto passa così da exhaustive AutoML search a un primo agente adattivo, trasparente e budget-aware.